Lab-Log



Big Data Analytics

Master Digital Business

OTH Amberg-Weiden

Hanna Graf | Matrikelnummer 57763151

Patricia Pfaller | Matrikelnummer 6076712

Abgabedatum: 10.11.2026

Prüfer: Prof. Dr. Schieder

1 Projektüberblick und Organisation

1.1 Geschäftsidee und Themenfindung

Ausgangspunkt war die Frage, wie freiwillig bereitgestellte Smartwatch-Aktivitätsdaten für einen nachvollziehbaren Personal Advisor und eine potenzielle Vermittlung von Sport-, Outdoor-, Freizeit- und Wellnessangeboten genutzt werden können. MOVA soll die Aktivitätsmuster der Nutzer analysieren, verständlich darstellen und ihnen darauf basierend individuell passende Angebote vorschlagen. Die Einnahmen sollen dabei durch Provisionen für erfolgreich vermittelte Angebote entstehen. Die Projektidee wurde im Verlauf mehrerer Vorlesungstermine diskutiert und hinsichtlich ihrer Umsetzbarkeit mit Prof. Dr. Schieder abgestimmt, bis wir uns schließlich für MOVA entschieden.

1.2 Zusammenarbeit, KI-Einsatz und CRISP-DM-Logik

Wir bearbeiteten die gesamte fachliche und technische Entwicklung gemeinsam in regelmäßigen Videokonferenzen. Da wir zunächst über vergleichbares, begrenztes Vorwissen verfügten, entschieden wir uns bewusst gegen eine feste Aufgabenaufteilung, um sämtliche Arbeitsschritte und Methoden gemeinsam zu verstehen.

Unser Vorgehen planten und diskutierten wir zunächst mit ChatGPT. Dabei entwickelten wir die einzelnen Arbeitsschritte, hinterfragten Vorschläge und formulierten gezielte Prompts, um die Methoden und Entscheidungen selbst nachvollziehen zu können. Diese übergaben wir anschließend schrittweise an Codex zur technischen Umsetzung. Durch die vorherige Planung wollten wir sowohl unser Verständnis der einzelnen Schritte sicherstellen als auch die begrenzten Nutzungskapazitäten von Codex effizient einsetzen und unnötige Entwicklungsversuche vermeiden. Lediglich die Videoproduktion teilten wir organisatorisch auf. Inhalt und Sprachgenerierung erarbeiteten wir gemeinsam. Hanna erarbeitete die Folien und erstellte die Aufnahmen, während Patricia den weiteren Videoschnitt und die Tonbearbeitung übernahm. Die abschließende Prüfung erfolgte gemeinsam.

Unsere Projektarbeit orientierte sich am iterativen CRISP-DM-Vorgehen. Im ersten Zyklus durchliefen wir alle sechs Phasen und kehrten aufgrund der Ergebnisse der Datenprüfung zwischenzeitlich zur Datengenerierung zurück. Die abschließende Evaluation führte zu einer neuen Hypothese, die wir im zweiten vollständigen CRISP-DM-Zyklus untersuchten. Eine zusammenfassende Übersicht der entstandenen Artefakte aus beiden CRISP-DM-Zyklen einschließlich der zusätzlichen Iterationen befindet sich im Anhang.

2 Prozessübersicht: zwei verbundene Zyklen

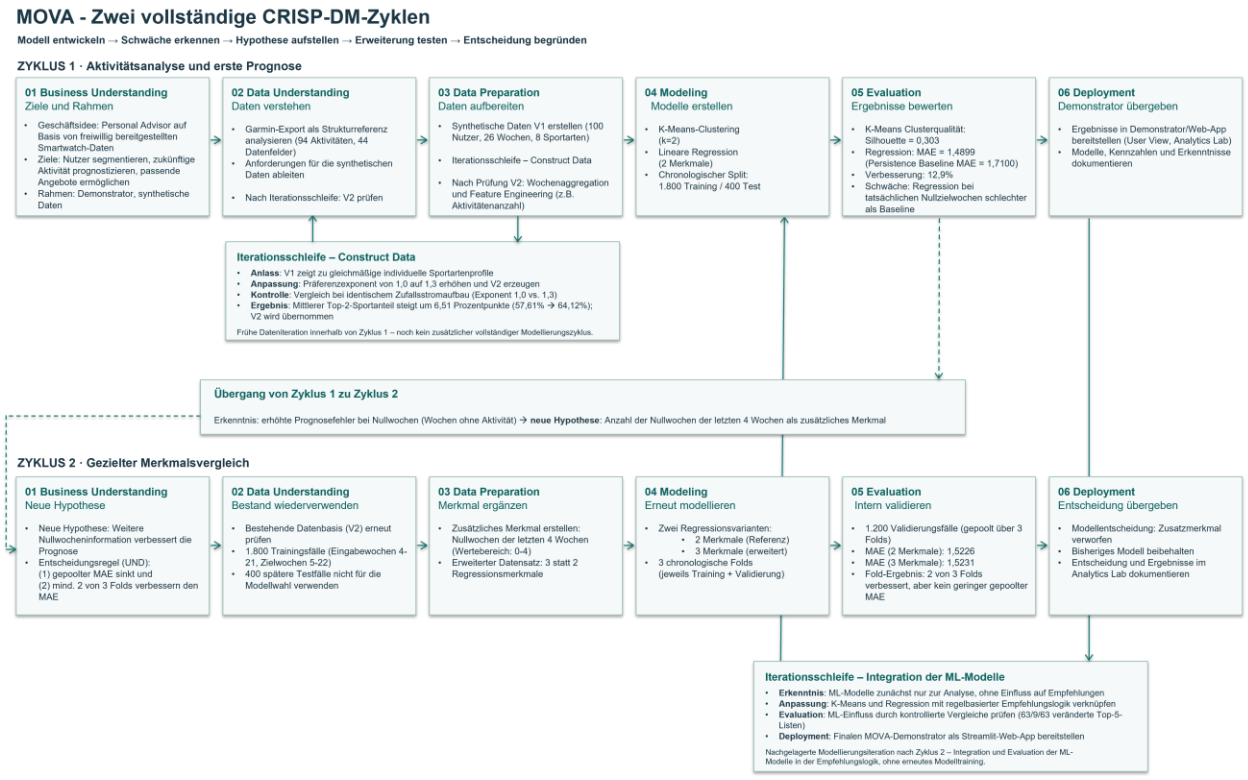


Abbildung 1: Iterativer Gesamtprozess. Eigene Projektdarstellung.

3 Zyklus 1 – Aktivitätsanalyse und Prognose

3.1 Business Understanding – Geschäftsziele und Analyse

01 Determine Business Objectives – Geschäftsziele und wirtschaftliche Perspektive

Aus unserer Geschäftsidee leiteten wir das Ziel ab, den möglichen Nutzen datenbasierter Aktivitätsanalysen und personalisierter Angebotsempfehlungen anhand eines Demonstrators zu untersuchen. Ein Provisionsmodell bildete dabei die wirtschaftliche Perspektive, deren tatsächliche Tragfähigkeit ohne reale Nutzungs- und Vermittlungsdaten jedoch nicht überprüft werden konnte.

02 Assess Situation – Ausgangssituation und Rahmenbedingungen

Uns standen lediglich begrenzte reale Aktivitätsdaten sowie ein überschaubarer Projektzeitraum zur Verfügung. Deshalb entschieden wir uns für einen Demonstrator mit synthetischen Daten und bewusst einfachen, nachvollziehbaren Analyseverfahren.

03 Determine Data Mining Goals – Analytische Ziele und Bewertungsverfahren

Wir legten drei Analyseziele fest: Nutzer anhand ihres Aktivitätsverhaltens mit K-Means segmentieren, ihre Aktivitätsanzahl für die Folgewoche mithilfe einer linearen Regression prognostizieren und Angebote anhand freiwilliger Interessen und beobachteter Sportarten regelbasiert priorisieren. Zur Beurteilung der Modellqualität dienten der Silhouette Score für die Clusterbildung sowie der mittlere absolute Fehler (MAE) und der Vergleich mit einer einfachen Persistence-Baseline für die Prognose.

04 Produce Project Plan – Projektvorgehen

Wir strukturierten die Umsetzung anhand der sechs CRISP-DM-Phasen und planten eine schrittweise Entwicklung mit Python, GitHub und Codex. Die Ergebnisse sollten in einer interaktiven Web-App mit User View und Analytics Lab zusammengeführt werden.

3.2 Data Understanding – Untersuchung der Ausgangsdaten

05 Collect Initial Data – Garmin und Polar als Ausgangsdaten

Zu Beginn betrachteten wir sowohl einen Garmin- als auch einen Polar-Datenexport. Da sich deren Datenstrukturen deutlich unterschieden, hätten wir die Daten für eine gemeinsame Auswertung zunächst vereinheitlichen müssen. Um diesen zusätzlichen Aufwand im Rahmen unseres Projekts zu vermeiden, entschieden wir uns, ausschließlich Garmin als Referenz zu verwenden. Die zwei originalen, individuellen Datenexporte sind aus Datenschutzgründen nicht im GitHub-Repository hinterlegt.

06 Describe Data – Struktur des Garmin-Exports

Der individuelle Garmin-Export umfasste 94 Aktivitäten mit insgesamt 44 Datenfeldern. Jede Zeile beschrieb eine einzelne aufgezeichnete Aktivität mit verschiedenen Merkmalen, darunter Datum, Sportart, Trainingsdauer und Distanz. Die Daten lagen somit auf Aktivitätsebene vor.

07 Explore Data – Mögliche Auswertungen und Analyseebenen

Wir prüften, welche Aktivitätsmuster sich anhand von Sportart, Trainingshäufigkeit und zeitlicher Verteilung untersuchen ließen. Da der Garmin-Export nur eine Person abbildete, konnten wir daraus keine unterschiedlichen Nutzergruppen ableiten. Die eigentliche Analyse der Nutzerprofile und Datenverteilungen erfolgte deshalb anhand der später generierten synthetischen Daten.

08 Verify Data Quality – Einschränkungen der Ausgangsdaten

Wir prüften, welche Einschränkungen bei der Verarbeitung der Ausgangsdaten zu berücksichtigen waren. Beispielsweise sind Distanzangaben nicht für jede Sportart sinnvoll und dürfen deshalb bei fehlender Angabe nicht automatisch mit null gleichgesetzt werden. Zusätzlich mussten wir bei der späteren Datengenerierung sicherstellen, dass unterschiedliche Aktivitätsmuster entstehen und fehlende Angaben nicht fälschlicherweise als tatsächliche Nullwerte interpretiert werden.

3.3 Data Preparation – Erste synthetische Datengenerierung

09 Select Data – Auswahl der Merkmale und des Datenumfangs

Auf Grundlage der untersuchten Datenstruktur wählten wir die für unsere Analysen benötigten Merkmale aus: Nutzerkennung, Aktivitätsdatum, Sportart, Trainingsdauer und gegebenenfalls Distanz. Für die synthetische Datengenerierung legten wir außerdem 100 Nutzer, einen einheitlichen Beobachtungszeitraum von 26 Wochen und acht Sportarten fest. Damit wollten wir unterschiedliche Aktivitätsmuster bei einem überschaubaren Datenumfang abbilden.

10 Clean Data – Qualitätsanforderungen an die Datengenerierung

Da wir die Daten selbst generierten, mussten wir zunächst keine bestehenden Aktivitätsdatensätze bereinigen. Stattdessen definierten wir Anforderungen an die erzeugten Daten, insbesondere gültige Nutzer- und Aktivitätskennungen, plausible Werte und einheitliche Sportartenbezeichnungen. Die tatsächliche Prüfung der generierten Daten erfolgte anschließend.

11 Construct Data – Erstellung des synthetischen Datensatzes V1

Zunächst planten wir mit ChatGPT die Logik zur synthetischen Datengenerierung und übergaben die entsprechenden Anforderungen anschließend an Codex, der den Generator in Python umsetzte. Dieser simulierte für jeden Nutzer unterschiedliche Trainingshäufigkeiten und individuelle Sportartenpräferenzen. Durch einen festgelegten Startwert für die Zufallszahlengenerierung stellten wir sicher, dass die Ergebnisse reproduzierbar waren. So entstand unsere erste Datenversion V1 mit insgesamt 6.665 Aktivitäten. Anschließend untersuchten wir die erzeugten Daten hinsichtlich ihrer Verteilungen und Plausibilität.

3.4 Iterationsschleife – Überprüfung und Verbesserung der Datengenerierung

07 Explore Data / 08 Verify Data Quality – Auffällige Sportartenverteilung in V1

Nachdem wir V1 generiert hatten, kehrten wir zu Data Understanding zurück, um die erzeugten Daten erstmals auf ihre Verteilungen und Plausibilität zu untersuchen. Dabei fiel uns auf, dass die individuellen Sportartenpräferenzen zu schwach ausgeprägt waren. Beispielsweise hatten 59 der 100 simulierten Nutzer innerhalb der 26 Wochen Aktivitäten in allen acht Sportarten. Wir gingen davon aus, dass deutlichere persönliche Sportartenschwerpunkte das tatsächliche Trainingsverhalten besser abbilden würden. Deshalb entschieden wir uns, die Datengenerierung anzupassen.

11 Construct Data – Anpassung des Präferenzexponenten

Wir erhöhten den sogenannten Präferenzexponenten von 1,0 auf 1,3. Dieser steuert, wie stark die individuellen Sportartenpräferenzen bei der zufälligen Auswahl berücksichtigt werden. Bei einem höheren Exponenten werden bereits bevorzugte Sportarten stärker gewichtet, während weniger bevorzugte Sportarten seltener ausgewählt werden. Dadurch wollten wir unterschiedliche sportliche Schwerpunkte deutlicher hervorheben. Anschließend erzeugten wir die überarbeitete Datenversion V2.

07 Explore Data / 08 Verify Data Quality – Kontrollierter Vergleich und Entscheidung für V2

Da bei der Weiterentwicklung auch der Aufbau der Zufallszahlengenerierung verändert worden war, hätte ein direkter Vergleich von V1 und V2 die Wirkung mehrerer Änderungen vermischt. Deshalb führten wir einen zusätzlichen Kontrolllauf durch, bei dem wir den ursprünglichen Präferenzexponenten von 1,0 mit dem Zufallsstromaufbau von V2 kombinierten. Im Vergleich zwischen diesem Kontrolllauf und V2 stieg der durchschnittliche Anteil der beiden häufigsten Sportarten von 57,61 % auf 64,12 %. Gleichzeitig sank die Anzahl der Nutzer, die alle acht Sportarten ausübten, von 58 auf 40. Damit bestätigten wir, dass die Anpassung innerhalb unseres Simulationsmodells zu deutlicheren individuellen Sportartenschwerpunkten führte. Wir übernahmen V2 deshalb als Datengrundlage für die weitere Analyse.

3.5 Data Preparation – Finale Datenaufbereitung für die Modellierung

09 Select Data – Auswahl der finalen V2-Daten

Nach der kontrollierten Überprüfung entschieden wir uns, ausschließlich V2 mit 6.465 Aktivitäten für die weitere Analyse zu verwenden. Wir beschränkten die Verarbeitung auf die zuvor ausgewählten Merkmale. Die Distanz schlossen wir aus, da sie für unsere geplanten Modelle nicht benötigt wurde.

10 Clean Data – Prüfung und Bereinigung der Aktivitätsdaten

Wir überprüften die Daten auf fehlende und ungültige Werte. Alle 6.465 Aktivitäten erfüllten unsere Anforderungen, sodass keine Datensätze entfernt werden mussten.

11 Construct Data – Wochenaggregation und Feature Engineering

Zunächst aggregierten wir die einzelnen Aktivitäten auf Wochenebene. Dazu erstellten wir für jeden der 100 Nutzer ein vollständiges Raster aus 26 Wochen. So entstanden 2.600 Nutzerwochen, darunter 558 Wochen ohne Aktivitäten. Diese Nullwochen behielten wir bewusst bei, da ihre Entfernung die durchschnittliche Aktivitätshäufigkeit um 27,33 % überschätzt hätte. Anschließend entwickelten wir zwei getrennte Datengrundlagen: Für K-Means fassten wir das Aktivitätsverhalten zu einem langfristigen Profil pro Nutzer zusammen. Für die Regression bildeten wir dagegen zeitlich aufeinanderfolgende Wochenbeobachtungen, um die Aktivitätsanzahl der jeweils folgenden Woche vorhersagen zu können.

12 Integrate Data – Zusammenführung der Datengrundlagen

Wir verknüpften die aufbereiteten Aktivitätsdaten über Nutzerkennungen und Kalenderwochen, um die wöchentlichen Aktivitätshäufigkeiten den jeweiligen Nutzern zuzuordnen und mit ihren sportartspezifischen Informationen zu kombinieren. Für das geplante Empfehlungssystem ergänzten wir selbst erstellte, synthetische Nutzerinteressen und einen fiktiven

Katalog mit 30 Sport-, Outdoor-, Freizeit- und Wellnessangeboten. Die Nutzerinteressen bildeten wir anhand der vier Kategorien ab. Der Angebotskatalog enthielt unter anderem die jeweilige Kategorie und den Preis. Damit schufen wir die Datengrundlage für die spätere regelbasierte Zuordnung passender Angebote.

13 Format Data – Skalierung und Vorbereitung der Modelleingaben

Für K-Means erstellten wir 100 Nutzerprofile mit jeweils neun Modellmerkmalen: der durchschnittlichen Aktivitätsanzahl pro Woche und den Anteilen der acht Sportarten. Da K-Means auf Abständen zwischen Datenpunkten basiert, standardisierten wir die Merkmale mit einem StandardScaler. Dieser zieht von jedem Wert den Mittelwert des jeweiligen Merkmals ab und teilt das Ergebnis durch dessen Standardabweichung. So verhinderten wir, dass Merkmale allein aufgrund ihrer unterschiedlichen Größenordnungen die Clusterbildung dominieren. Zusätzlich gewichteten wir die acht Sportartenanteile mit dem Faktor $1/\sqrt{8}$, damit diese Merkmalsgruppe insgesamt nicht zu stark ins Gewicht fiel. Für die lineare Regression erstellten wir 2.200 zeitlich geordnete Beispiele. Als Eingangsmerkmale verwendeten wir die Aktivitätsanzahl der aktuellen Woche und den Durchschnitt der letzten vier Wochen. Die Zielvariable war die Aktivitätsanzahl der darauffolgenden Woche. Anschließend teilten wir die Regressionsdaten chronologisch in 1.800 Trainings- und 400 Testfälle auf. Dadurch stellten wir sicher, dass für das Training keine Beobachtungen aus dem späteren Testzeitraum verwendet wurden.

3.6 Modeling – Entwicklung der ML-Modelle

14 Select Modeling Technique – Auswahl der Modellierungsverfahren

Wir wählten K-Means zur Segmentierung der Nutzer und eine lineare Regression zur Prognose ihrer wöchentlichen Aktivitätsanzahl. Beide Verfahren eigneten sich aufgrund ihrer einfachen Umsetzung und Nachvollziehbarkeit für unseren Demonstrator. Ergänzend entwickelten wir ein regelbasiertes Empfehlungssystem, das freiwillige Interessen und historische Sportartenpräferenzen berücksichtigt.

15 Generate Test Design – Festlegung der Modellbewertung

Für K-Means verglichen wir verschiedene Clusteranzahlen und wiederholten die Berechnungen mit unterschiedlichen Initialisierungen, um die Qualität und Stabilität der Gruppierung zu untersuchen. Da keine vorgegebenen Clusterzugehörigkeiten existierten, bewerteten wir die Ergebnisse anhand interner Qualitätsmaße. Für die lineare Regression nutzten wir die zuvor festgelegte chronologische Aufteilung in 1.800 Trainings- und 400 Testfälle. Zur Beurteilung der Prognosegenauigkeit verwendeten wir den mittleren absoluten Fehler (MAE) und eine einfache Persistence-Baseline. Beim Empfehlungssystem überprüften wir anhand synthetischer Nutzerprofile, ob die freiwilligen Interessen als verbindlicher Kategorienfilter wirkten und die bisherigen Sportartenpräferenzen bei der Priorisierung berücksichtigt wurden.

16 Build Model – Training der Modelle und Entwicklung der Empfehlungslogik

Für die technische Umsetzung verwendeten wir die Python-Bibliothek scikit-learn, die verschiedene Verfahren des maschinellen Lernens bereitstellt.

K-Means: Wir verglichen die Clusterzahlen k = 2, 3, 6 und 8 mit jeweils 20 unterschiedlichen Zufallsstarts. Da K-Means seine Clusterzentren zunächst zufallsabhängig festlegt, überprüften wir damit, ob die Gruppenzuordnungen auch bei veränderten Startbedingungen stabil blieben. Die Übereinstimmung der Ergebnisse bewerteten wir mit dem Adjusted Rand Index (ARI). Anschließend trainierten wir das finale Modell mit zwei Clustern.

Lineare Regression: Wir trainierten das Modell auf den 1.800 Trainingsfällen. Dabei bestimmte der Algorithmus die Koeffizienten, mit denen die beiden Eingangsmerkmale zur Prognose der folgenden Woche kombiniert werden. Die 400 Testfälle wurden nicht zum Training verwendet.

Regelbasiertes Empfehlungssystem: Zusätzlich entwickelten wir eine Empfehlungslogik, die freiwillig ausgewählte Interessen und bisher ausgeübte Sportarten berücksichtigt. Dafür ergänzten wir die fiktiven Angebote um passende Sportarten-Tags, die kennzeichnen, für welche Sportarten ein Angebot relevant ist. Angebote, die sowohl zur Interessenkategorie als auch zu einer ausgeübten Sportart passten, erhielten die höchste Priorität. Angebote mit ausschließlich passender Interessenkategorie wurden nachrangig berücksichtigt. Nicht ausgewählte Interessenkategorien blieben ausgeschlossen.

17 Assess Model – Beurteilung der Modelle

Wir überprüften die Modelle zunächst auf Plausibilität und technische Funktionsfähigkeit. Bei K-Means kontrollierten wir die vollständige Clusterzuordnung, deren Stabilität bei unterschiedlichen Zufallsstarts und die inhaltliche Interpretierbarkeit der Nutzergruppen. Bei der Regression prüften wir die Prognosen für alle 400 Testfälle auf Vollständigkeit und Plausibilität. Für das Empfehlungssystem kontrollierten wir die Einhaltung der Interessenfilter und die korrekte Priorisierung passender Sportarten-Tags.

3.7 Evaluation – Bewertung der Modellergebnisse

18 Evaluate Results – Bewertung der Analyseergebnisse

K-Means: Zur Bewertung der Clusterqualität verwendeten wir den Silhouette Score. Dieser misst, wie ähnlich sich Nutzer innerhalb eines Clusters sind und wie deutlich sich die Cluster voneinander unterscheiden. Zusätzlich überprüften wir die Stabilität der Gruppierungen mit dem Adjusted Rand Index (ARI), der die Übereinstimmung zweier Clusterzuordnungen unter Berücksichtigung zufälliger Übereinstimmungen bewertet.

Tabelle 1: Ergebnisse der K-Means-Segmentierung

Kennzahl	Ergebnis
Gewählte Clusteranzahl	k = 2
Silhouette Score	0,303
ARI	1,000
Cluster 0	57 Nutzer
Cluster 1	43 Nutzer
Durchschnittliche Aktivitäten/Woche Cluster 0	1,54
Durchschnittliche Aktivitäten/Woche Cluster 1	3,75

Von den untersuchten Clusteranzahlen erreichte k = 2 den höchsten Silhouette Score. Der ARI von 1 zeigte, dass die Clusterzuordnungen trotz unterschiedlicher Zufallsstarts vollständig übereinstimmten. Die Clusterbildung erwies sich unter den untersuchten Bedingungen somit als stabil. Die beiden Gruppen unterschieden sich insbesondere hinsichtlich ihrer durchschnittlichen wöchentlichen Aktivitätshäufigkeit und ließen sich als Nutzer mit geringerer beziehungsweise höherer Trainingshäufigkeit interpretieren. Der Silhouette Score von 0,303 deutete auf eine mäßige Trennung der Cluster hin. Dennoch konnten wir zwei stabile und nachvollziehbare Nutzersegmente identifizieren, die eine sinnvolle Grundlage für unseren Demonstrator bildeten.

Lineare Regression: Die Prognosequalität bewerteten wir anhand des mittleren absoluten Fehlers (MAE) und der Wurzel des mittleren quadratischen Fehlers (RMSE). Während der MAE die durchschnittliche absolute Abweichung zwischen Prognose und tatsächlicher Aktivitätsanzahl angibt, gewichtet der RMSE größere Prognosefehler stärker. Als Vergleich verwendeten wir eine Persistence-Baseline, die die Aktivitätsanzahl der aktuellen Woche unverändert als Prognose für die Folgewoche übernimmt.

Tabelle 2: Prognosequalität der Regression im Vergleich zur Baseline

Verfahren (400 Testfälle)	MAE	RMSE
Persistence-Baseline	1,7100	2,3108
Lineare Regression (zwei Merkmale)	1,4899	1,9085

Die lineare Regression reduzierte den MAE gegenüber der Baseline um rund 12,9 % und erzielte auch beim RMSE ein besseres Ergebnis. Damit zeigte sich auf den synthetischen Testdaten ein messbarer Vorteil gegenüber der einfachen Fortschreibung der letzten Aktivitätshäufigkeit. Daraus lässt sich jedoch keine entsprechende Prognosequalität für reale Nutzer ableiten. Bei der genaueren Untersuchung der Prognosefehler betrachteten wir zusätzlich die 92 Testfälle, in denen in der vorherzusagenden Woche tatsächlich keine Aktivität stattfand. In dieser Teilgruppe erreichte die Regression einen MAE von 1,8783, während die Persistence-Baseline mit 1,3804 besser abschnitt. Beim RMSE war die Regression dagegen weiterhin günstiger. Die insgesamt bessere Prognoseleistung galt somit nicht für jede betrachtete Teilgruppe gleichermaßen. Da die tatsächliche Aktivitätsanzahl der Folgewoche zum Prognosezeitpunkt noch unbekannt ist, konnten wir daraus keine Regel ableiten, bei zukünftigen Nullwochen automatisch die Baseline zu verwenden. Dies würde Informationen aus der Zukunft voraussetzen und zu Data Leakage führen. Die Teilgruppenanalyse zeigte somit eine konkrete Schwäche unserer Regression, obwohl sie im Gesamtergebnis besser als die Baseline abschnitt.

Regelbasiertes Empfehlungssystem: Die ursprüngliche Empfehlungslogik berücksichtigte die freiwillig ausgewählten Interessenkategorien und die historisch ausgeübten Sportarten. Angebote außerhalb der ausgewählten Kategorien wurden ausgeschlossen, während passende Sportarten-Tags die Priorisierung beeinflussten. Ohne ausgewählte Interessen wurden keine Empfehlungen ausgegeben. Preise und Rabatte flossen nicht in die Rangfolge ein. Ein Vergleich zeigte bei 64 von 100 Nutzern eine veränderte Top-5-Zusammensetzung durch die Berücksichtigung der Sportartenpassung. Damit konnten wir nachweisen, dass die historischen Aktivitätsdaten die Empfehlungen beeinflussten. Ob diese Veränderungen tatsächlich zu relevanteren Angeboten oder einer höheren Kaufwahrscheinlichkeit führten, ließ sich ohne reale Nutzerreaktionen jedoch nicht bewerten.

19 Review Process – Überprüfung des Vorgehens

Bei der abschließenden Überprüfung bestätigten wir die Nachvollziehbarkeit der Datenaufbereitung und Modellbewertung. Festgelegte Zufallsstarts, die vollständige Berücksichtigung von Nullwochen, der chronologische Train-Test-Split und der Baseline-Vergleich unterstützten die methodische Qualität. Die Aussagekraft blieb jedoch auf synthetische Daten beschränkt. Insbesondere die Übertragbarkeit auf reale Nutzer sowie die tatsächliche Relevanz der Empfehlungen konnten wir nicht überprüfen.

20 Determine Next Steps – Ableitung der nächsten Schritte

Nach der Evaluation entschieden wir uns, die entwickelten Modelle und die regelbasierte Empfehlungslogik zunächst in einem Demonstrator bereitzustellen. Gleichzeitig zeigte die Analyse der 92 Testfälle ohne Aktivitäten in der Folgewoche eine Schwäche der Regression beim MAE. Daraus entwickelten wir die Hypothese, dass die Anzahl der Nullwochen innerhalb der letzten vier Wochen zusätzliche Prognoseinformationen liefern könnte. Diese wollten wir nach dem Deployment in einem zweiten CRISP-DM-Zyklus überprüfen.

3.8 Deployment – Bereitstellung des ersten MOVA-Demonstrators V1

21 Plan Deployment – Planung der Bereitstellung

Für die Bereitstellung des ersten Demonstrators entschieden wir uns für Streamlit Community Cloud. Dadurch konnten wir die Web-App über einen Link aufrufen und unabhängig voneinander testen. Den Entwicklungsstand und die zugehörigen Analyseartefakte verwalteten wir weiterhin über GitHub.

22 Plan Monitoring and Maintenance – Planung der Überwachung und Wartung

Da MOVA ausschließlich mit synthetischen Daten arbeitete, war keine kontinuierliche Überwachung realer Nutzeraktivitäten erforderlich. Stattdessen sicherten wir die technische Funktionsfähigkeit durch automatisierte Tests, GitHub-Versionierung und die Überprüfung der veröffentlichten Streamlit-App. Besonders wichtig waren die korrekte Verarbeitung der Nutzerprofile, die Einhaltung der freiwilligen Datenfreigaben und die regelbasierte Angebotsauswahl. Für einen späteren Produktiveinsatz wären zusätzlich regelmäßige Prüfungen der Daten- und Modellqualität sowie des Datenschutzes notwendig.

23 Produce Final Report – Dokumentation der Ergebnisse

Die Ergebnisse des ersten Zyklus dokumentierten wir in GitHub anhand der aufbereiteten Datensätze, trainierten Modelle, Clusterzuordnungen und Modellkennzahlen. Zusätzlich machten wir die wichtigsten Analyseergebnisse im Analytics Lab nachvollziehbar. Diese Dokumentation bildete die Grundlage für unser späteres CRISP-DM-Lab-Log.

24 Review Project – Rückblick auf den ersten Zyklus

Der erste Zyklus verdeutlichte uns die Bedeutung einer sorgfältigen Datenaufbereitung und differenzierten Modellbewertung. Besonders die Überarbeitung der synthetischen Sportartenverteilung, die Berücksichtigung von Nullwochen und die Analyse unterschiedlicher Prognosefehler lieferten wichtige Erkenntnisse für den zweiten Zyklus.

4 Zyklus 2 – Gezielter Merkmalsvergleich

Der zweite CRISP-DM-Zyklus knüpfte an eine Erkenntnis aus der Evaluation des ersten Zyklus an. Zunächst schlossen wir jedoch alle sechs Phasen einschließlich des Deployments ab. Der Iterationspfeil in Abbildung 1 verdeutlicht daher den fachlichen Ausgangspunkt und nicht den unmittelbaren zeitlichen Übergang.

4.1 Business Understanding – Geschäftsziele und Analyse

01 Determine Business Objectives – Ziel der Modellverbesserung

Im zweiten Zyklus wollten wir die Prognosequalität unserer linearen Regression gezielt verbessern. Anlass war die Erkenntnis, dass das Modell bei zukünftigen Wochen ohne Aktivitäten hinsichtlich des MAE schlechter als die Persistence-Baseline abschnitt. Die ursprüngliche Geschäftsidee und die übrigen Analyseziele blieben unverändert.

02 Assess Situation – Ausgangssituation und Rahmenbedingungen

Als Grundlage standen uns der bestehende synthetische V2-Datensatz, die aufbereiteten Nutzerwochen sowie das Regressionsmodell mit zwei Eingangsmerkmalen zur Verfügung. Da wir ausschließlich eine zusätzliche Einflussgröße untersuchen wollten, waren weder neue Aktivitätsdaten noch Änderungen an der K-Means-Segmentierung oder der Empfehlungslogik erforderlich.

03 Determine Data Mining Goals – Hypothese und analytisches Ziel

Wir stellten die Hypothese auf, dass die Anzahl der Nullwochen innerhalb der letzten vier Wochen zusätzliche Informationen über das Aktivitätsverhalten liefert und dadurch die Prognosegenauigkeit verbessert. Dazu wollten wir das

bestehende Regressionsmodell mit zwei Merkmalen mit einer erweiterten Variante mit drei Merkmalen vergleichen. Das zusätzliche Merkmal sollte nur übernommen werden, wenn die erweiterte Regression sowohl einen niedrigeren gepoolten MAE als auch eine Verbesserung in mindestens zwei der drei Validierungsabschnitte erzielte.

04 Produce Project Plan – Planung des Modellvergleichs

Wir planten, das zusätzliche Merkmal aus den vorhandenen Wochenaggregationen abzuleiten und beide Modellvarianten unter identischen Bedingungen zu vergleichen. Neben dem bisherigen chronologischen Testzeitraum sollten mehrere zeitlich aufeinanderfolgende Validierungsabschnitte berücksichtigt werden, um die Ergebnisse nicht nur anhand einer einzelnen Datenaufteilung zu beurteilen. Auf dieser Grundlage wollten wir entscheiden, ob das erweiterte Modell übernommen oder die ursprüngliche Regression beibehalten werden sollte.

4.2 Data Understanding – Untersuchung der Nullwochen

05 Collect Initial Data – Übernahme der bestehenden Datengrundlage

Wir verwendeten erneut den synthetischen V2-Datensatz mit 100 Nutzern und 26 Wochen sowie die bereits aufbereiteten 2.600 Nutzerwochen einschließlich 558 Nullwochen. Neue Daten waren nicht erforderlich.

06 Describe Data – Beschreibung der relevanten Daten

Grundlage waren die zeitlich geordneten wöchentlichen Aktivitätsanzahlen je Nutzer. Wochen ohne aufgezeichnete Aktivitäten wurden als Nullwochen berücksichtigt.

07 Explore Data – Untersuchung der Nullwochen

Wir betrachteten die zeitlichen Aktivitätsverläufe der Nutzer und untersuchten dabei insbesondere das Auftreten von Nullwochen als Grundlage für die Bildung des zusätzlichen Merkmals.

08 Verify Data Quality – Prüfung der Datenqualität

Wir kontrollierten die Vollständigkeit und zeitliche Reihenfolge der Nutzerwochen. Für das neue Merkmal durften ausschließlich bereits beobachtete Wochen verwendet werden, um Data Leakage zu vermeiden.

4.3 Data Preparation – Erweiterung der Regressionsmerkmale

09 Select Data – Auswahl der bestehenden Datengrundlage

Wir übernahmen die zeitlich geordneten Nutzerwochen aus V2 und beschränkten uns auf die für die Regression benötigten Aktivitätshäufigkeiten. Die bestehenden beiden Eingangsmerkmale und die Zielvariable behielten wir unverändert bei, um den Einfluss des zusätzlichen Merkmals isoliert untersuchen zu können.

10 Clean Data – Prüfung und Bereinigung der Aktivitätsdaten

Da die Daten bereits in Zyklus 1 geprüft worden waren, kontrollierten wir lediglich, dass die Nullwochen und die zeitliche Reihenfolge erhalten blieben.

11 Construct Data – Erstellung des zusätzlichen Merkmals

Wir ergänzten die Regressionsdaten um das Merkmal *zero_weeks_last4*. Dieses zählt für jeden Nutzer, in wie vielen der letzten vier Wochen keine Aktivität aufgezeichnet wurde. Der Wert liegt somit zwischen 0 und 4. Für seine Berechnung verwendeten wir ausschließlich die bereits bekannten Aktivitätsanzahlen einschließlich der aktuellen Woche. Dadurch konnten wir das Merkmal zum Prognosezeitpunkt bestimmen, ohne Informationen aus der vorherzusagenden Woche zu verwenden.

12 Integrate Data – Zusammenführung der Modellmerkmale

Wir ergänzten die bestehenden Regressionsbeobachtungen um das neue Merkmal. Dadurch entstanden zwei vergleichbare Modellvarianten mit zwei beziehungsweise drei Eingangsmerkmalen und identischer Zielvariable.

13 Format Data – Vorbereitung des Modellvergleichs

Für einen kontrollierten Vergleich behielten wir die bisherigen Trainings- und Testbeobachtungen bei. Zusätzlich bereiteten wir die Daten für mehrere chronologisch aufeinanderfolgende Validierungsabschnitte vor. Dabei verwendeten beide Modellvarianten jeweils dieselben Beobachtungen und Zeiträume, sodass Unterschiede in der Prognoseleistung auf das zusätzliche Merkmal zurückgeführt werden konnten.

4.4 Modeling – Vergleich der Regressionsmodelle

14 Select Modeling Technique – Auswahl der Modellvarianten

Wir behielten die lineare Regression als Modellierungsverfahren bei und verglichen zwei Varianten: das ursprüngliche Modell mit den Merkmalen current_week und avg_last_4 sowie ein erweitertes Modell mit dem zusätzlichen Merkmal

zero_weeks_last4. Da beide Varianten dasselbe Verfahren verwendeten, konnten wir gezielt untersuchen, welchen zusätzlichen Prognosebeitrag die Nullwochen-Historie lieferte.

15 Generate Test Design – Chronologische Kreuzvalidierung

Für einen zuverlässigen Modellvergleich führten wir eine zeitlich fortschreitende Kreuzvalidierung mit drei sogenannten *Expanding-Window-Folds* durch. Dabei vergrößerten wir den Trainingszeitraum schrittweise und überprüften die Modelle jeweils anhand der darauffolgenden vier Wochen.

Tabelle 3: Aufteilung der Trainings- und Validierungsdaten in drei chronologische Folds

Fold	Training: Eingabewochen	Validierung: Eingabewochen	Fälle Training / Validierung
1	4-9	10-13	600/400
2	4-13	14-17	1.000/400
3	4-17	18-21	1.400/400

Die vorherzusagenden Zielwochen lagen jeweils eine Woche später. Alle 100 Nutzer einer Kalenderwoche blieben im selben Zeitblock. Beide Modellvarianten wurden innerhalb jedes Folds auf denselben Trainings- und Validierungsdaten verglichen. Als zentrales Vergleichskriterium verwendeten wir den über alle 1.200 Validierungsfälle zusammengefassten MAE und betrachteten ergänzend die Ergebnisse der einzelnen Folds.

16 Build Model – Training der Modellvarianten

Wir trainierten beide Regressionsvarianten mit scikit-learn und dem Verfahren Ordinary Least Squares (OLS). Für jeden der drei Folds wurden die Modellkoeffizienten anhand der jeweiligen Trainingsdaten neu berechnet, sodass insgesamt sechs Modelltrainings erfolgten. Das bereits trainierte Modell aus Zyklus 1 konnten wir nicht verwenden, da es teilweise schon spätere Validierungsdaten kannte. Während eines Validierungsabschnitts blieben die Koeffizienten unverändert; neu beobachtete Wochen konnten jedoch für die folgenden Einwochenprognosen als historische Eingaben genutzt werden.

17 Assess Model – Beurteilung der Modelle

Wir überprüften, ob beide Modellvarianten innerhalb jedes Folds dieselben Validierungsdaten verwendeten und keine zukünftigen Informationen in das Training einflossen. Zusätzlich kontrollierten wir die korrekte Modellschätzung durch einen unabhängigen Vergleich der Regressionskoeffizienten und eine Überprüfung des Matrixrangs.

4.5 Evaluation – Bewertung des Modellvergleichs

18 Evaluate Results – Bewertung der Prognoseergebnisse

Für die Bewertung verglichen wir die Prognosefehler der beiden Regressionsvarianten und der Persistence-Baseline über insgesamt 1.200 Validierungsfälle aus drei Folds. Als entscheidendes Gütemaß verwendeten wir den gepoolten MAE, der den durchschnittlichen absoluten Prognosefehler über alle Validierungsfälle angibt.

Tabelle 4: Prognosevergleich der Regressionsvarianten und der Persistence-Baseline

Modell (1.200 Fälle)	Gepoolter MAE	RMSE
Persistence-Baseline	1,729167	2,365551
OLS, 2 Merkmale	1,522613	1,962287
OLS, 3 Merkmale	1,523105	1,962666

Beide Regressionsvarianten schnitten besser als die Baseline ab. Das zusätzliche Merkmal verbesserte den MAE zwar in Fold 1 und 3 geringfügig, verschlechterte ihn jedoch in Fold 2 stärker. Insgesamt stieg der gepoolte MAE dadurch um 0,000493. Auch bei den 259 Validierungsfällen mit einer tatsächlichen Aktivitätsanzahl von null zeigte sich keine Verbesserung. Hier erhöhte sich der MAE durch das zusätzliche Merkmal von 1,708690 auf 1,713798. Unsere Hypothese bestätigte sich damit unter den untersuchten Bedingungen nicht.

19 Review Process – Überprüfung des Vergleichsverfahrens

Der Modellvergleich erfolgte unter identischen Bedingungen und ohne spätere Validierungsdaten im Training. Da dieselben Nutzer mehrfach vorkamen und sich historische Zeiträume überschnitten, waren die 1.200 Validierungsfälle nicht vollständig unabhängig. Die Ergebnisse erlaubten daher eine Modellentscheidung innerhalb unseres synthetischen Datensatzes, jedoch keinen Nachweis statistischer Signifikanz oder allgemeiner Übertragbarkeit. Auch die MAE-Werte aus Zyklus 1 und 2 sind aufgrund unterschiedlicher Datenaufteilungen nicht direkt vergleichbar.

20 Determine Next Steps – Entscheidung über die Modellvariante

Die erweiterte Regression verbesserte den MAE zwar in zwei der drei Folds, erreichte jedoch keinen niedrigeren gepoolten MAE. Da somit nicht beide zuvor festgelegten Bedingungen erfüllt waren, entschieden wir uns gegen das zusätzliche Merkmal und behielten die ursprüngliche Regression mit zwei Eingangsmerkmalen bei. Der zweite Zyklus lieferte damit ein

begründetes negatives Ergebnis: Die untersuchte Erweiterung brachte innerhalb unseres Vergleichs keinen messbaren Prognosevorteil. Wir entschieden uns deshalb, das bisherige Modell unverändert beizubehalten und diese Entscheidung für die anschließende Bereitstellung zu dokumentieren.

4.6 Deployment – Dokumentation der Modellentscheidung und Weiterentwicklung zu MOVA V2

21 Plan Deployment – Planung der Bereitstellung

Da das zusätzliche Merkmal keinen Prognosevorteil brachte, behielten wir die ursprüngliche Regression bei und planten, die Ergebnisse des Modellvergleichs im Analytics Lab darzustellen.

22 Plan Monitoring and Maintenance – Planung der Überwachung und Wartung

Die technische Überprüfung der Anwendung führten wir wie im ersten Zyklus fort. Zusätzlich sicherten wir den Modellvergleich durch automatisierte Tests und Integritätsprüfungen ab. Dabei kontrollierten wir die zeitlich korrekte Validierung, die Reproduzierbarkeit der Kennzahlen und die Unveränderheit des ursprünglichen Regressionsmodells. Das Analytics Lab verwendete gespeicherte Ergebnisse, statt bei jedem Aufruf Modelle neu zu trainieren. Ein produktives Monitoring war für den Demonstrator mit synthetischen Daten nicht vorgesehen.

23 Produce Final Report – Dokumentation des Modellvergleichs

Wir speicherten die 1.200 Validierungsprognosen je Verfahren, Foldmetriken, Modellparameter und Entscheidungsnachweise als separate Artefakte. Im weiterentwickelten MOVA-Demonstrator V2 ergänzten wir im Analytics Lab einen Bereich, der die Hypothese, die Berechnung der Nullwochen, den chronologischen Modellvergleich und die begründete Verwerfung des zusätzlichen Merkmals visualisierte. Damit waren sowohl die Ergebnisse als auch die methodischen Entscheidungen des zweiten Zyklus nachvollziehbar dokumentiert.

24 Review Project – Rückblick auf den zweiten Zyklus

Der zweite Zyklus zeigte, dass zusätzliche Merkmale nicht zwangsläufig die Prognose verbessern. Der kontrollierte Vergleich ermöglichte uns dennoch eine nachvollziehbare Modellentscheidung.

5 Iterationsschleife – Integration der ML-Modelle

Nachdem wir die Hypothese aus Zyklus 2 verworfen hatten, behielten wir das ursprüngliche Regressionsmodell bei und arbeiteten mit dem MOVA-Demonstrator V2 weiter. Bei anschließenden Funktionstests stellten wir fest, dass die Ergebnisse von K-Means und Regression zwar im Analytics Lab visualisiert wurden, die eigentliche Angebotsauswahl jedoch nicht beeinflussten. Um die Ergebnisse unserer ML-Modelle nicht nur zu visualisieren, sondern auch für die Personalisierung zu nutzen, entschieden wir uns für eine gezielte Weiterentwicklung der Empfehlungslogik und kehrten dafür zur CRISP-DM-Phase Modeling zurück.

5.1 Modeling – Integration der ML-Modelle in die Empfehlungslogik

14 Select Modeling Technique – Auswahl des Modellierungsansatzes

Wir entschieden uns, die bestehende regelbasierte Empfehlungslogik beizubehalten und gezielt um die Ergebnisse der bereits trainierten ML-Modelle zu erweitern. Die freiwillig ausgewählten Interessen sollten weiterhin als verbindlicher Filter dienen, während die historisch ausgeübten Sportarten bei der Priorisierung berücksichtigt wurden. Zusätzlich sollte K-Means die Auswahl geeigneter Ausrüstungsvarianten und die Regression die Auswahl passender Laufkursvarianten beeinflussen. Da beide Modelle bereits trainiert und evaluiert waren, konzentrierten wir uns auf ihre Integration in die Empfehlungslogik statt auf ein erneutes Training.

15 Generate Test Design – Entwicklung des Testkonzepts

Zur Überprüfung der ML-Integration planten wir einen Ablationstest mit allen 100 synthetischen Nutzerprofilen. Dabei untersuchten wir den Einfluss der beiden Modelle, indem wir K-Means und Regression gezielt einzeln sowie gemeinsam aktivierten und die Ergebnisse mit einer rein regelbasierten Variante ohne ML-Einfluss verglichen. Als Prüfgröße verwendeten wir die Anzahl der Nutzer, bei denen sich mindestens eine der Top-5-Empfehlungen gegenüber der regelbasierten Ausgangsvariante veränderte. So konnten wir feststellen, ob und in welchem Umfang die beiden ML-Modelle tatsächlich zur Angebotsauswahl beitrugen.

16 Build Model – Erweiterung der Empfehlungslogik

Wir integrierten die Ergebnisse der bereits trainierten ML-Modelle in die regelbasierte Empfehlungslogik. Die gespeicherte K-Means-Clusterzuordnung steuert die Auswahl von Laufschuhen und Wandersets für gelegentliche beziehungsweise häufige Nutzung. Die lineare Regression prognostiziert anhand der letzten abgeschlossenen Woche und des Vierwochendurchschnitts die Gesamtzahl der Aktivitäten in der Folgewoche. Ab drei prognostizierten Aktivitäten wird ein Laufkurs mit drei wöchentlichen Terminen bevorzugt; bei weniger als zwei Aktivitäten ein Einzeltermin. Im Bereich von zwei

bis unter drei Aktivitäten greift die Standardvariante. Die ML-Modelle verändern ausschließlich die Angebotsvariante innerhalb einer Gruppe, nicht deren Rangfolge. Interessenfilter, historische Sportartenpriorisierung und freiwillige Datenfreigabe bleiben bestehen. Die konkreten Zuordnungen und Schwellenwerte sind regelbasierte Demonstrationsannahmen und wurden nicht aus dem Modelltraining abgeleitet.

Tabelle 5: Entscheidungsregeln zur ML-gestützten Angebotsempfehlung

ML-Modell	Eingangsgröße	Konkrete Entscheidungsregel
K-Means	Cluster 0	Bevorzugung von Angeboten für gelegentliche Nutzung: O031 (Laufschuhe), O036 (Wandersets)
K-Means	Cluster 1	Bevorzugung von Angeboten für häufige Nutzung: O032 (Laufschuhe), O037 (Wandersets)
Lineare Regression	Prognose < 2 Aktivitäten/Woche	Auswahl des Laufworkshops mit einem Termin (O033)
Lineare Regression	Prognose 2 bis < 3 Aktivitäten/Woche	Keine explizite Variantenpräferenz; Rückfall auf O033
Lineare Regression	Prognose ≥ 3 Aktivitäten/Woche	Auswahl des Laufkurses mit drei Terminen pro Woche (O034)

Hinweis: Die Regeln greifen nur bei gültigen Modellinformationen und passender Sporthistorie. Es handelt sich um demonstrative Zuordnungen, nicht um empirisch validierte Empfehlungen.

Durch diese Erweiterung beeinflussten die ML-Ergebnisse erstmals die konkrete Angebotsauswahl des MOVA-Demonstrators.

17 Assess Model – Überprüfung der ML-Integration

Wir überprüften, ob die erweiterten Auswahlregeln die gespeicherten Clusterzuordnungen und Regressionsprognosen korrekt verwendeten. Zusätzlich kontrollierten wir, dass die Interessenfilter und die freiwillige Datenfreigabe weiterhin eingehalten wurden. Durch den Vergleich der Empfehlungslisten mit deaktivierten und aktivierten ML-Einflüssen prüften wir, ob beide Modelle tatsächlich in die Angebotsentscheidung eingriffen.

5.2 Evaluation – Integration der ML-Modelle in die Empfehlungslogik

18 Evaluate Results – Bewertung der Ergebnisse

Wir führten den geplanten Ablationstest mit allen 100 synthetischen Nutzerprofilen durch. Dabei verglichen wir die Top-5-Empfehlungen der rein regelbasierten Ausgangsvariante mit drei Varianten, in denen K-Means und Regression einzeln oder gemeinsam aktiviert waren.

Tabelle 6: Einfluss der ML-Modelle auf die Top-5-Empfehlungen

Vergleich mit der regelbasierten Ausgangsvariante	Nutzer mit veränderten Top-5-Empfehlungen
Nur K-Means aktiviert	63 von 100 (63%)
Nur Regression aktiviert	9 von 100 (9%)
Beide ML-Modelle aktiviert	63 von 100 (63%)

Die Ergebnisse zeigten, dass beide ML-Modelle die Angebotsauswahl tatsächlich beeinflussten. K-Means wirkte sich dabei auf deutlich mehr Nutzerprofile aus als die Regression. Bei gemeinsamer Aktivierung veränderten sich ebenfalls bei 63 Nutzern die Top-5-Empfehlungen. Die zusätzliche Regression erhöhte somit die Anzahl der betroffenen Nutzer gegenüber der alleinigen K-Means-Aktivierung nicht. Dies schließt jedoch nicht aus, dass sie die Empfehlungen innerhalb dieser Nutzergruppe zusätzlich veränderte. Insgesamt konnten wir die funktionale Einbindung beider Modelle nachweisen. Ob die veränderten Empfehlungen tatsächlich relevanter waren, ließ sich aufgrund der ausschließlich synthetischen Daten und fehlender realer Nutzertests jedoch nicht beurteilen.

19 Review Process – Überprüfung des Vorgehens

Für alle vier Varianten verwendeten wir dieselben Nutzerprofile, Interessen und Angebotsdaten; lediglich der ML-Einfluss wurde verändert. Damit konnten wir den technischen Einfluss der Modelle isoliert untersuchen. Da ausschließlich Veränderungen der Top-5-Empfehlungen erfasst wurden und keine realen Nutzerbewertungen oder Kaufentscheidungen vorlagen, konnten wir weder eine höhere Empfehlungsqualität noch einen wirtschaftlichen Nutzen nachweisen.

20 Determine Next Steps – Festlegung der nächsten Schritte

Da beide ML-Modelle nachweislich Einfluss auf die Angebotsauswahl hatten und die bestehenden Interessenfilter erhalten blieben, entschieden wir uns, die erweiterte Empfehlungslogik in den finalen MOVA-Demonstrator zu übernehmen. Für die anschließende Deployment-Phase planten wir, die überarbeitete Anwendung als MOVA V3 bereitzustellen und die Funktionsweise der modellgestützten Empfehlungen für die Nutzer nachvollziehbar darzustellen.

5.3 Deployment – Bereitstellung des finalen MOVA-Demonstrators V3

21 Plan Deployment – Planung der Bereitstellung

Wir entschieden uns, die erweiterte Empfehlungslogik in MOVA V3 zu übernehmen und ihren Einfluss sowohl in der User View als auch im Analytics Lab nachvollziehbar darzustellen.

22 Plan Monitoring and Maintenance – Überwachung und Wartung

Für den finalen Demonstrator behielten wir die GitHub-Versionierung und die technischen Funktionstests bei. Besonders wichtig war die Überprüfung, dass die modellabhängigen Auswahlregeln korrekt angewendet wurden und die freiwillige Datenfreigabe sowie die Interessenfilter weiterhin funktionierten. Da MOVA ausschließlich mit synthetischen Daten arbeitete und kein Produktiveinsatz vorgesehen war, richteten wir kein kontinuierliches Monitoring realer Nutzerdaten ein.

23 Produce Final Report – Dokumentation und Bereitstellung

Wir integrierten die erweiterte Empfehlungslogik und die zusätzlichen Angebote in den bestehenden Anwendungscode und übernahmen die Änderungen in den Hauptentwicklungsstand auf GitHub. Anschließend stellten wir den funktionsfähigen MOVA-Demonstrator V3 über Streamlit bereit. In der User View beeinflussten nun auch die Ergebnisse von K-Means und Regression die personalisierten Angebote. Das Analytics Lab ergänzten wir um eine Visualisierung der Ablationstests, die den Einfluss beider Modelle auf die Top-5-Empfehlungen verdeutlichte. Die bisherigen Analysen und der historische Vergleich der regelbasierten Empfehlungslogik blieben erhalten.

24 Review Project – Abschließender Projektrückblick

Die Iteration verdeutlichte, dass die Entwicklung und Evaluation von ML-Modellen allein nicht ausreichen. Erst ihre Integration in die Empfehlungslogik ermöglichte den vorgesehenen Einfluss auf personalisierte Angebote. Ob diese dadurch relevanter wurden, blieb offen.

6 Erfolgskriterien und abschließende Projektbewertung

Zu Beginn definierten wir unsere analytischen Ziele, legten jedoch noch keine konkreten Kriterien zur Erfolgsmessung fest. Erst durch das Bewertungsschema erkannten wir diese Lücke. Im weiteren Projektverlauf konkretisierten wir deshalb unsere Erfolgskriterien, um sowohl die analytische Modellleistung als auch den fachlichen Nutzen von MOVA bewerten zu können.

Tabelle 7: Bewertung der MOVA-Erfolgskriterien

Erfolgskriterium	Ergebnis und Einordnung
Datenqualität	Vollständige Wochenhistorien einschließlich Nullwochen; ausschließlich synthetische Daten
Segmentierung	Zwei interpretierbare Aktivitätscluster; moderate Trennschärfe (Silhouette 0,303)
Prognosequalität	MAE gegenüber der Baseline um 12,9 % verbessert; Schwächen bei Nullaktivität
ML-Integration	Einfluss beider Modelle auf Empfehlungen nachgewiesen; keine Aussage über deren Qualität
Fachlicher und wirtschaftlicher Nutzen	Personalisierte Angebotsauswahl technisch umgesetzt; Empfehlungsrelevanz, Vermittlungsquote und Provisionserlöse mangels realer Nutzungsdaten nicht bewertbar

7 Irrwege, Korrekturen und Erkenntnisse

ChatGPT und Codex unterstützten uns bei der Konzeption, Programmierung und Weiterentwicklung von MOVA. Dabei führten unzureichende Anforderungen und zunächst nicht erkannte Implementierungslücken zu mehreren Fehlern, die wir erst durch gezielte Überprüfungen aufdeckten.

Tabelle 8: Irrwege, Korrekturen und Erkenntnisse im Projektverlauf

Irrweg bzw. Problem	Ursache, Korrektur und Erkenntnis
Unzureichende Datenvielfalt in V1	Bei der ersten KI-gestützten Datengenerierung hatten wir keine ausreichenden Anforderungen an die Vielfalt der Sportartenpräferenzen formuliert. Dadurch entstand ein zu gleichförmiger Datensatz, der unterschiedliche Nutzerprofile nur unzureichend abbildete und die Aussagekraft der geplanten Segmentierung einschränkte. Erst bei der Datenexploration erkannten wir diesen Fehler, präzisierten unsere Anforderungen und überarbeiteten die Generierungslogik für V2.
Fehlende ML-Integration	Wir gingen zunächst aufgrund der KI-gestützten Entwicklung und ihrer Beschreibungen davon aus, dass K-Means und Regression bereits aktiv in die Empfehlungen einflossen. Tatsächlich wurden die Modellergebnisse jedoch nur visualisiert, während die Angebotsauswahl weiterhin regelbasiert erfolgte. Diesen grundlegenden Fehler erkannten wir erst bei späteren Funktionstests. Daraufhin mussten wir zur Modellierungsphase zurückkehren, beide Modelle in die Empfehlungslogik integrieren und ihre Wirkung durch Ablationstests überprüfen.

Unvollständige Umsetzung von MOVA V3	Bei der Weiterentwicklung konzentrierten wir uns zunächst ausschließlich auf die ML-Integration in der User View und übersahen, dass die neuen Ergebnisse im Analytics Lab noch nicht nachvollziehbar dargestellt wurden. Dadurch war die finale Anwendung zwar funktional erweitert, die Evaluation der ML-Integration blieb für Betrachter jedoch unsichtbar. Nach einer erneuten Überprüfung ergänzten wir deshalb einen separaten Bereich zur Visualisierung der Ablationstests.

Diese Irrwege verdeutlichten uns, dass KI-generierte Lösungen trotz zunächst plausibler Ergebnisse wesentliche Anforderungen verfehlen können. Wir lernten, Anforderungen präziser zu formulieren und die tatsächliche Umsetzung nicht nur anhand von KI-Beschreibungen, sondern durch eigene Funktionstests und Ergebnisvergleiche zu überprüfen.

8 Reproduzierbarkeit

Unser MOVA-Projekt wird in einem GitHub-Repository versioniert und dokumentiert (Referenzcommit: 1751fcfbf711c27fdc0bc6e31c6bf090308e9ffb). Die technische Umgebung basiert auf Python 3.12.14; die benötigten Bibliotheken und Versionen sind in requirements-dashboard-lock.txt festgehalten.

Die Verarbeitungskette lässt sich anhand der Skripte im Ordner src/ nachvollziehen. Sie umfasst die synthetische Datengenerierung (data_generation.py), Datenaufbereitung (data_preparation_*.py), K-Means-Segmentierung (modeling_kmeans_*.py) und Regression (modeling_regression_*.py). Die Untersuchungen aus Zyklus 2 und die ML-Ablationstests sind über cycle2_compare.py beziehungsweise ml_recommendation_evaluation.py dokumentiert. Die zugehörigen Datensätze, Modelle und Ergebnisse liegen in data/ und outputs/.

Für reproduzierbare Berechnungen verwendeten wir festgelegte Zufallsseeds (Datengenerierung: 42; K-Means: 42), dokumentierte Datenaufteilungen und gespeicherte Modellparameter. Der Demonstrator lässt sich mit streamlit run app.py starten und wurde zusätzlich erfolgreich über Streamlit Community Cloud bereitgestellt. Die detaillierte Ausführungsreihenfolge ist in der Projektdokumentation hinterlegt.

Damit sind die Ergebnisse beider CRISP-DM-Zyklen und der nachgelagerten ML-Integration anhand der gespeicherten Artefakte nachvollziehbar. Die exakte Reproduktion hängt jedoch von der verwendeten Softwareumgebung und teilweise vom Git-Stand ab.

Mit der Abgabe des vollständigen Projekts stellen wir auch das gesamte GitHub-Repository einschließlich des Quellcodes, der Datensätze, Modelle und Ergebnisartefakte zur Verfügung.

9 Fazit

Mit MOVA haben wir ein funktionsfähiges Empfehlungssystem entwickelt, das synthetische Aktivitätsdaten mithilfe von K-Means und linearer Regression für personalisierte Angebote nutzt. Die technische Integration beider Modelle konnten wir durch Ablationstests nachweisen. Ob die Empfehlungen dadurch tatsächlich relevanter werden und ein wirtschaftlicher Mehrwert entsteht, bleibt offen und müsste anhand realer Nutzerdaten und Nutzertests überprüft werden.

Anhang

CRISP-DM-Artefaktübersicht – MOVA

Zusammenfassung beider vollständiger CRISP-DM-Zyklen einschließlich der zusätzlichen Iterationen

Tabelle A1: CRISP-DM-Artefaktübersicht des MOVA-Projekts

Business Understanding	Data Understanding	Data Preparation	Modeling	Evaluation	Deployment
Determine Business Objectives • Geschäftsidee MOVA und Provisionsmodell • Ziel: Aktivitätsanalyse und personalisierte Angebote • Konkretisierte Erfolgskriterien **Assess Situation** • Garmin- und Polar-Export als Datenreferenz • Datenschutz- und Zeitbeschränkungen • Entscheidung für synthetische Daten **Determine Data Mining Goals** • Nutzersegmentierung (K-Means) • Aktivitätsprognose (lineare Regression) • Personalisierte Angebotsempfehlungen • Hypothese Zyklus 2: zusätzliches Nullwochenmerkmal • Bewertungsmaße: Silhouette, MAE und Baseline **Produce Project Plan** • Projektplan entlang CRISP-DM • Python, GitHub, ChatGPT und Codex • Streamlit-Demonstrator mit User View und Analytics Lab	**Collect Initial Data** • Garmin- und Polar-Export gesichtet; Garmin als Referenz ausgewählt • Synthetischer V2-Datensatz für beide Zyklen übernommen **Describe Data** • 6.465 Aktivitäten, 8 Sportarten • 2.600 Nutzerwochen, davon 558 Nullwochen **Explore Data** • Sportartenverteilung und Trainingshäufigkeit • Aktivitätsverläufe und Nullwochen • Einschränkung: Daten nur einer Person • Vergleich der Datenverteilung V1/V2 **Verify Data Quality** • Prüfung der Datenstruktur und Plausibilität • Sportartspezifische fehlende Distanzwerte berücksichtigt • Anforderungen an synthetische Daten abgeleitet	**Select Data** • Relevante Aktivitäts- und Sportartenmerkmale • K-Means- und Regressionsdaten • Unveränderte Zielvariable im Modellvergleich **Clean Data** • Prüfung der Aktivitätsdaten • Vollständige Wochenhistorien einschließlich Nullwochen • Kontrolle gültiger Werte und Kennungen **Construct Data** • Synthetische Datengenerierung V1 und V2 • Iteration (Data Understanding ↔ Data Preparation): Präferenzexponent 1,0 → 1,3; kontrollierter Vergleich der Datenverteilung V1/V2 • Wochenaggregation und Feature Engineering • K-Means-Nutzerprofile • Regression: current_week, avg_last_4 • Zyklus 2: zero_weeks_last4 **Integrate Data** • Zusammenführung von Nutzer- und Aktivitätsdaten • Interessen- und Angebotsdaten • Erweiterung um acht Angebote (O031–O038) **Format Data** • StandardScaler und gewichtete Sportartenanteile • K-Means-Eingangsdaten • Regression: 2.200 Fälle, Split 1.800/400 • Drei chronologische Validierungsfolds	**Select Modeling Techniques** • K-Means-Clustering • Lineare Regression (OLS) • Regelbasierte Empfehlungslogik **Generate Test Design** • Clustervergleich: k = 2, 3, 6 und 8 • Silhouette und Clusterstabilität • Chronologischer Train-Test-Split • Persistence-Baseline • Expanding-Window-Validierung (3 Folds) • Ablationstest mit vier Empfehlungsvarianten **Build Model** • K-Means-Modell mit zwei Clustern • Regression mit zwei Merkmalen • Vergleichsmodell mit drei Merkmalen • Regelbasierte Angebotsempfehlungen • Iteration (Modeling → Evaluation → Deployment): ML-Integration in die Empfehlungslogik und Ablationstests **Assess Model** • Prüfung der Clusterzuordnung und Stabilität • Plausibilitätsprüfung der Prognosen • Koeffizienten- und Matrixrangprüfung • Funktionstests der Empfehlungslogik	**Evaluate Results** • K-Means: Silhouette 0,303; ARI 1,000 • Regression Zyklus 1: MAE 1,4899 • Persistence-Baseline: MAE 1,7100 • Verbesserung: 12,9 % • Zyklus 2: MAE 1,5226 (2 Merkmale) vs. 1,5231 (3 Merkmale); Zusatzmerkmal verworfen • Ablation: 63/100, 9/100 und 63/100 **Review Process** • Analyse von 92 Nullwochen-Testfällen • Prüfung der zeitlichen Datenaufteilung • Vergleich identischer Validierungsbedingungen • Grenzen synthetischer Daten und fehlender Nutzertest **Determine Next Steps** • Hypothese für Zyklus 2 entwickelt • Zusätzliches Regressionsmerkmal verworfen • Ursprüngliche Regression beibehalten • ML-Integration in MOVA V3 umgesetzt	**Plan Deployment** • Streamlit Community Cloud • User View und Analytics Lab • Weiterentwicklung MOVA V1 → V2 → V3 **Plan Monitoring and Maintenance** • Automatisierte Funktionstests • GitHub-Versionierung • Prüfung von Interessenfiltern und Datenfreigabe • Kein produktives Monitoring **Produce Final Report** • Gespeicherte Daten und Modelle • Evaluationsartefakte und Modellkennzahlen • Visualisierung im Analytics Lab • Dokumentation im Lab Log **Review Project** • Erkenntnisse aus beiden CRISP-DM-Zyklen • Dokumentierte Irrwege und Korrekturen • Grenzen der technischen und wirtschaftlichen Aussagekraft